

Chapter 12. LiveGuardrail과 tool_guard — 실행 전 차단

이 챕터에서 배우는 것

- `@agent_eval` 과 `@tool_guard` 가 왜 같은 함수에 함께 붙을 수 없는지
- `live_guardrail_session` 이 세션 단위로 무엇을 묶는지
- 이 방어가 실제로 막아주는 것과, 명시적으로 못 막아주는 것

이런 분이 먼저 읽으면 좋습니다: 지금까지 이 책은 "결과가 나온 뒤 채점"만 다뤘다. 결과가 나오기 **전에** 막는 메커니즘이 궁금한 분.

12.1 두 축의 경계 — 다시 확인한다

8장 (§ 8.4)에서 이미 이 경계를 예고했다 — 결과(응답 문자열)를 반환하는 함수는

`@agent_eval` 로 사후 채점하고, 파일 쓰기 같은 부작용이 있는 함수는

`@tool_guard` 로 실행 전에 막는다. `scaffold.py` 의 `write_chapter_stub()` 가 그 실제 사례다.

```
@tool_guard(audit_blocked=True)
def write_chapter_stub(
    project_dir: str, part_dir_name: str, chapter_file_name: str,
    chapter_no: int, chapter_title: str,
) -> str:
    ...
```

`@tool_guard` 가 감싸는 함수는 **원시 타입(str/int)만 인자로 받는다** — 코드 주석이 이유를 밝힌다. "LiveGuardrail 내부 로직이 도구 호출 인자를 로깅/직렬화할 수 있어, 임의의 dataclass보다 JSON-safe한 값만 넘기는 편이 안전하다." 계측이 인자를 그대로 기록·감사할 수 있어야 하므로, 함수 시그니처 자체가 그 요구에 맞춰 설계됐다.

12.2 세션이 반복을 판정하는 단위다

`@tool_guard` 가 붙은 함수를 단독으로 부르는 것만으로는 아무 검사도 일어나지 않는다 — `live_guardrail_session` 으로 감싸야 한다.

```
def scaffold_project(project_dir: Path, chapters: list[ChapterSpec]) -> list[str]:
    """승인된 목차 전체를 스캐폴딩한다. 세션 하나로 묶어 loop_detection이 작동하게 한다."""
    guardrail = LiveGuardrail(loop_detection=LoopDetectionConfig(consecutive_repeat_threshold=5))
    results: list[str] = []
    with live_guardrail_session(guardrail, task_id=f"scaffold_{project_dir.name}"):
        for spec in chapters:
            results.append(write_chapter_stub(str(project_dir), spec.part_dir_name, spec.chapter_file_name, spec.chapter_no, spec.chapter_title))
    return results
```

함수 docstring이 이 구조의 이유를 명시한다 — "세션 하나로 묶어 `loop_detection` 이 작동하게 한다." `LoopDetectionConfig(consecutive_repeat_threshold=5)` 는 **같은 세션 안에서** 같은 호출이 5번 연속 반복되면 차단한다 — 세션 경계 밖에서는 "반복"이라는 개념 자체가 성립하지 않는다. 챕터 여러 개를 스캐폴딩하는 반복문 전체가 `with live_guardrail_session(...)` 블록 하나 안에 있는 것도 이 때문이다 — 챕터마다 새 세션을 열면 "직전 호출과 같은가"를 비교할 기준 자체가 리셋된다.

12.3 실제로 막아주는 것 — 그리고 못 막아주는 것

`scaffold.py` 최상단 주석은 이례적으로 정직하게, 이 방어가 못 하는 것까지 밝힌다.


"주의 — 정확히 밝혀둘 것: `ScopeConfig` 는 파일 경로가 아니라 도구 이름 allow/forbid 목록이다... '프로젝트 디렉토리 밖 쓰기 금지'는 Harness Config가 대신 해주는 기능이 아니라 이 모듈이 직접 구현하는 방어 코드다. LiveGuardrail이 실제로 막아주는 것은 `LoopDetectionConfig` 기반의 폭주(동일 호출 반복) 탐지뿐이다."


즉 `write_chapter_stub()` 함수 본문에 있는 경로 검사(3장 § 3.5에서 이미 확인한 코드)는 SDK의 `LiveGuardrail` 이 대신 해주는 게 아니다 — **개발자가 직접 짤 방어**

코드다. `@tool_guard` 와 `live_guardrail_session` 이 자동으로 처리하는 것은 오직 반복 탐지뿐이다.

위험	막는 주체	코드 위치
같은 호출이 5번 연속 반복	<code>LiveGuardrail (LoopD etectionConfig)</code>	자동, <code>@tool_guard</code> 에 내장
프로젝트 디렉토리 밖 경로 쓰기	직접 짠 방어 코드	<code>write_chapter_stub()</code> 본문의 <code>if resolved_project not in resolved_target.parents</code>

이 표가 이 챕터의 핵심 교훈이다 — **"LiveGuardrail을 붙였다"는 사실만으로 모든 위험이 자동으로 막힌다고 가정하면 안 된다.** SDK가 제공하는 것과, 애플리케이션이 직접 짜야 하는 것을 정확히 구분해야 한다.





12.4 세션 밖 호출 — fail-open이 기본값이다

`@tool_guard` 가 붙은 함수를 `live_guardrail_session` 없이 호출하면 어떻게 될까 — 예외가 나지 않는다. `RuntimeWarning` 만 내고 가드 없이 원본 함수를 그대로 실행한다(`fail_closed=False` 가 기본값). 이 선택은 다른 `fail_on_*` 계열 플래그들과 반대 방향이다 — 대부분의 검증 플래그는 "지정 안 하면 안전하게 막는다"인데, `tool_guard` 는 "지정 안 하면 조용히 통과시키되 경고만 낸다"를 기본으로 삼는다. 이는 기존 코드(가드를 아직 안 붙인 호출부)를 깨뜨리지 않기 위한 하위 호환 우선 설계다

— 정말로 강제하고 싶다면 `tool_guard(fail_closed=True)` 로 명시적으로 켜야 한다.

이 챕터의 핵심

- `@tool_guard` 는 결과가 아니라 부작용을 막는 축이다. `@agent_eval` (9장 이전 챕터들)과 서로 겹치지 않는 완전히 다른 검사 시점이다.
- `live_guardrail_session` 이 "반복"을 판정하는 경계다. 세션 밖에서는 비교 기준이 없다.
- SDK가 자동으로 막는 것과 애플리케이션이 직접 짜야 하는 것은 다르다.
`scaffold.py` 는 이 경계를 주석으로 명시적으로 밝혀둔다.
- 세션 없이 호출해도 기본은 fail-open이다. 강제하려면 `fail_closed=True` 를 명시해야 한다.

참고 자료

- `src/book_forge/agents/scaffold.py` — 전체
- `Agent-Evaluator/agent_evaluator/gates/live_guardrail.py` —
`tool_guard` · `live_guardrail_session`

다음 챕터는 같은 `LiveGuardrail` 이 완전히 다른 위험 — 여러 저자가 동시에 같은 챕터를 저장하려 할 때의 충돌 — 을 막는 데 어떻게 재사용되는지 다룬다.